

# Ejercicios Tema 5

## Percepción

Curso 2019/2020

1. Sean  $A$  y  $B$  dos clases con la misma probabilidad a priori y f.d. condicional de clase de tipo Bernoulli:

$$p(\mathbf{x} | A) \sim Be_2(\mathbf{p}_A) \quad \text{con} \quad \mathbf{p}_A = \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix} \quad p(\mathbf{x} | B) \sim Be_2(\mathbf{p}_B) \quad \text{con} \quad \mathbf{p}_B = \begin{pmatrix} 0.75 \\ 0.25 \end{pmatrix}$$

- a) Plantea el clasificador Bernoulli dados los parámetros anteriores  
b) Calcula el error global de este clasificador Bernoulli
2. Tenemos  $N = 24$  vectores binarios bidimensionales aleatoriamente extraídos de  $C = 2$  distribuciones de Bernoulli independientes:

$n$	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20	21	22	23	24
$x_{n1}$	1	0	0	1	1	1	1	1	0	1	1	0	1	1	0	0	0	1	0	0	1	0	0	0
$x_{n2}$	0	0	1	0	0	0	0	0	1	1	0	1	1	0	0	0	0	0	1	1	0	0	1	0
$c_n$	1	1	1	1	1	1	1	1	1	1	1	1	2	2	2	2	2	2	2	2	2	2	2	2

- a) Calcula el clasificador Bernoulli más probable con respecto a estos datos  
b) Repite el cálculo anterior considerando únicamente el primer bit  
c) Compara los dos clasificadores Bernoulli calculados
3. Tenemos  $N = 12$  vectores binarios tridimensionales aleatoriamente extraídos de  $C = 2$  distribuciones Bernoulli independientes:

$n$	1	2	3	4	5	6	7	8	9	10	11	12
$x_{n1}$	1	1	1	1	1	1	1	1	0	1	1	0
$x_{n2}$	1	0	0	1	1	1	0	1	0	1	0	0
$x_{n3}$	1	0	1	0	1	0	0	0	0	0	0	0
$c_n$	1	1	1	1	1	1	2	2	2	2	2	2

- a) Calcula el clasificador Bernoulli más probable  
b) Clasifica la siguiente muestra de test  $\mathbf{y} = (0 \ 0 \ 1)^t$   
c) Suaviza los prototipos Bernoulli con truncamiento simple ( $\epsilon = 0.1$ )  
d) Suaviza los prototipos Bernoulli con muestra ficticia
4. Se tiene un clasificador en dos clases basado en distribuciones Bernoulli bidimensionales, de forma que para la clase 1 se tiene  $\mathbf{p}_1 = (0.3 \ 0.2)^t$ , y para la clase 2 se tiene  $\mathbf{p}_2 = (0.6 \ 0.8)^t$ . Se pide clasificar la muestra  $\mathbf{y} = (0 \ 1)^t$  empleando  $\arg \max_c P(c | \mathbf{y})$  sabiendo que la probabilidad condicional  $p(\mathbf{y} | c) = \prod_d (p_{cd} y_d + (1 - p_{cd})(1 - y_d))$  y las probabilidades a priori son idénticas para ambas clases.
5. Tenemos  $N = 12$  vectores binarios tridimensionales aleatoriamente extraídos de  $C = 3$  distribuciones Bernoulli independientes:

$n$	1	2	3	4	5	6	7	8	9	10	11	12
$x_{n1}$	1	1	1	1	0	0	0	0	0	1	1	0
$x_{n2}$	0	0	0	0	1	1	0	1	1	1	1	1
$x_{n3}$	1	0	1	0	1	1	1	1	0	0	0	0
$c_n$	1	1	1	1	2	2	2	2	3	3	3	3

- a) Estima todos los parámetros del clasificador Bernoulli más probable  
b) Suaviza los prototipos Bernoulli con truncamiento simple ( $\epsilon = \frac{1}{8}$ ) y clasifica la muestra  $\mathbf{y} = (0 \ 0 \ 1)^t$

6. Tenemos  $N = 12$  vectores 4-dimensionales etiquetados:

$n$	1	2	3	4	5	6	7	8	9	10	11	12
$x_{n1}$	1	0	1	1	0	1	0	0	0	0	0	0
$x_{n2}$	0	1	1	1	0	1	0	0	0	0	0	0
$x_{n3}$	0	0	0	0	0	0	1	1	0	1	0	1
$x_{n4}$	0	0	0	0	0	0	1	1	1	1	1	1
$c_n$	1	1	1	1	1	1	2	2	2	2	2	2

- Calcula los parámetros del clasificador Bernoulli más probable respecto a estos datos, asumiendo que han sido aleatoriamente extraídos de  $C = 2$  distribuciones Bernoulli independientes
- Suaviza los parámetros Bernoulli del apartado anterior mediante truncamiento simple de  $\epsilon = \frac{1}{3}$

7. Tenemos  $N = 9$  vectores binarios bidimensionales aleatoriamente extraídos de  $C = 2$  distribuciones Bernoulli independientes:

$n$	1	2	3	4	5	6	7	8	9
$x_{n1}$	1	0	0	1	1	1	1	1	0
$x_{n2}$	0	0	1	0	0	0	0	0	1
$c_n$	1	1	1	2	2	2	2	2	2

- Calcula los parámetros del clasificador Bernoulli más probable respecto a estos datos
- Calcula el error global
- Suaviza los parámetros Bernoulli de ambas clases aplicando truncamiento simple con  $\epsilon = \frac{1}{4}$
- Clasifica el vector  $\mathbf{y} = (1, 1)^t$  con el clasificador Bernoulli **suavizado** del apartado anterior

8. Sea  $A$  y  $B$  dos clases con igual probabilidad a priori y probabilidades condicionales de tipo multinomial:

$$p(\mathbf{x} | A) \sim Mult_2(x_+ = 5, \mathbf{p}_A) \quad \text{con} \quad \mathbf{p}_A = \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix} \quad p(\mathbf{x} | B) \sim Mult_2(x_+ = 5, \mathbf{p}_B) \quad \text{con} \quad \mathbf{p}_B = \begin{pmatrix} 0.75 \\ 0.25 \end{pmatrix}$$

Para el correspondiente clasificador multinomial:

- Calcula las funciones discriminantes
- Calcula el error global

9. Tenemos  $N = 20$  vectores de cuentas bidimensionales aleatoriamente extraídos de  $C = 2$  distribuciones multinomiales independientes de longitud 4:

$n$	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
$x_{n1}$	4	3	3	4	2	3	4	2	3	2	2	1	1	4	1	2	3	3	3	0
$x_{n2}$	0	1	1	0	2	1	0	2	1	2	2	3	3	0	3	2	1	1	1	4
$c_n$	1	1	1	1	1	1	1	1	1	1	2	2	2	2	2	2	2	2	2	2

- Calcula el clasificador multinomial más probable respecto a estos datos.
- Calcula la probabilidad *a posteriori* para todo  $\mathbf{x} = (x_1, x_2)^t \in \{0, 1, 2, 3, 4\}^2 : x_1 + x_2 = 4$ .

10. Tenemos  $N = 18$  vectores de cuentas 5-dimensionales aleatoriamente extraídos de  $C = 3$  distribuciones multinomiales independientes:

$n$	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18
<i>car</i>	0	0	0	0	2	0	2	0	3	2	2	0	0	0	1	1	0	0
<i>people</i>	2	0	1	0	2	1	0	3	1	0	2	0	0	0	0	0	0	0
<i>game</i>	0	2	0	0	0	0	1	2	2	3	0	4	2	0	1	1	0	1
<i>party</i>	3	1	4	1	0	1	0	0	0	0	0	0	0	0	0	0	0	0
<i>shell</i>	0	0	0	0	0	0	3	0	0	0	0	0	1	1	0	0	1	0
$c_n$	1	1	1	1	1	1	2	2	2	2	2	2	3	3	3	3	3	3

- Calcula el clasificador multinomial más probable respecto a estos datos
- Clasifica la siguiente muestra de test  $\mathbf{y} = (1 \ 1 \ 1 \ 1 \ 1)^t$

- c) Suaviza los parámetros mediante Laplace con  $\epsilon = 0.1$
- d) Suaviza los parámetros con descuento absoluto de  $\epsilon = 0.05$  y *backing-off* utilizando como distribución generalizada la distribución uniforme
- e) Como el anterior pero con interpolación
11. Dados los parámetros de un clasificador multinomial  $\hat{\mathbf{p}}_1 = (0.5 \ 0.3 \ 0.2 \ 0.0 \ 0.0)^t$  y  $\hat{\mathbf{p}}_2 = (0.0 \ 0.0 \ 0.3 \ 0.3 \ 0.4)^t$  con probabilidades *a priori* idénticas, clasifica la muestra de test  $\mathbf{y} = (1 \ 1 \ 1 \ 1 \ 1)^t$  tras aplicar los siguientes suavizados:
- Laplace con  $\epsilon = 0.1$
  - Descuento absoluto con  $\epsilon = 0.05$  y *backing-off* utilizando como distribución generalizada la distribución uniforme
12. Tenemos  $N = 12$  vectores de cuentas 5-dimensionales aleatoriamente extraídos de  $C = 2$  distribuciones multinomiales independientes:

$n$	1	2	3	4	5	6	7	8	9	10	11	12
$x_{n1}$	1	2	1	1	2	1	0	0	0	0	0	0
$x_{n2}$	2	1	0	1	2	0	0	0	0	0	0	0
$x_{n3}$	0	0	0	0	0	0	1	1	0	1	0	1
$x_{n4}$	1	0	2	1	0	2	1	2	1	1	2	1
$x_{n5}$	0	0	0	0	0	0	1	3	1	1	1	1
$c_n$	1	1	1	1	1	1	2	2	2	2	2	2

- a) Calcula los parámetros del clasificador multinomial más probable respecto a estos datos
- b) Suaviza los parámetros multinomial mediante Laplace con  $\epsilon = 0.2$
- c) Suaviza los parámetros con descuento absoluto de  $\epsilon = 0.1$  e interpolación usando como distribución generalizada, la distribución uniforme
- d) Suaviza los parámetros con descuento absoluto de  $\epsilon = 0.1$  e interpolación usando como distribución generalizada, la distribución  $g = (0.1 \ 0.2 \ 0.4 \ 0.2 \ 0.1)$ , donde  $g_i$  es la probabilidad asociada a la dimensión  $i$ -ésima de  $\mathbf{p}_c$
- e) Clasifica la muestra de test  $\mathbf{y} = (1 \ 1 \ 1 \ 1 \ 1)^t$  con el clasificador multinomial resultante de aplicar los parámetros suavizados del apartado b)
13. Tenemos  $N = 12$  vectores 4-dimensionales etiquetados:

$n$	1	2	3	4	5	6	7	8	9	10	11	12
$x_{n1}$	1	0	1	1	0	1	0	0	0	0	0	0
$x_{n2}$	0	1	1	1	0	1	0	0	0	0	0	0
$x_{n3}$	0	0	0	0	0	0	1	1	0	1	0	1
$x_{n4}$	0	0	0	0	0	0	1	1	1	1	1	1
$c_n$	1	1	1	1	1	1	2	2	2	2	2	2

- a) Calcula los parámetros del clasificador multinomial más probable respecto a estos datos, asumiendo que han sido aleatoriamente extraídos de  $C = 2$  distribuciones multinomiales independientes
- b) Suaviza los parámetros multinomiales del apartado anterior con descuento absoluto de  $\epsilon = 0.2$  e interpolación usando como distribución generalizada, la distribución uniforme
14. Tenemos  $N = 6$  cadenas de longitud  $x_+ = 2$  procedentes de un vocabulario  $V = \{a, b, c\}$  aleatoriamente extraídas de  $C = 2$  distribuciones multinomiales independientes, donde las muestras de la clase 1 son  $\mathcal{X}_1 = \{aa, bb, aa\}$  y las muestras de la clase 2 son  $\mathcal{X}_2 = \{ab, bc, ac\}$ . Se pide
- a) Calcula los parámetros del clasificador multinomial más probable respecto a estos datos
- b) Calcula el error global (Nota:  $0^0 = 1$ )
- c) Suaviza los parámetros multinomiales de ambas clases aplicando Laplace con  $\epsilon = \frac{1}{3}$
- d) Clasifica la cadena  $y = cc$  con el clasificador multinomial **suavizado** del apartado anterior

15. Tenemos  $N = 16$  vectores de cuentas 5-dimensionales aleatoriamente extraídos de  $C = 2$  distribuciones multinomiales independientes:

$n$	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16
$x_{n1}$	1	2	1	1	2	1	1	0	0	0	0	0	0	0	0	0
$x_{n2}$	2	1	0	1	2	0	0	3	0	0	0	0	0	0	0	0
$x_{n3}$	0	0	0	0	0	0	0	0	1	1	0	1	0	1	1	1
$x_{n4}$	1	0	2	1	0	2	3	3	1	2	1	1	2	1	1	3
$x_{n5}$	0	0	0	0	0	0	0	0	1	3	1	1	1	1	3	1
$c_n$	1	1	1	1	1	1	1	1	2	2	2	2	2	2	2	2

- a) Calcula los parámetros del clasificador multinomial más probable respecto a estos datos  
b) Suaviza los parámetros multinomial mediante Laplace con  $\epsilon = 0.2$   
c) Suaviza los parámetros con descuento absoluto de  $\epsilon = 0.05$  e interpolación usando como distribución generalizada la distribución uniforme  
d) Clasifica la muestra de test  $\mathbf{y} = (1 \ 1 \ 1 \ 1 \ 1)^t$  con el clasificador multinomial resultante de aplicar los parámetros suavizados del apartado c).
16. Sea  $A$  y  $B$  dos clases con igual probabilidad *a priori* y probabilidades condicionales de clase gaussianas:

$$p(\mathbf{x} | A) \sim \mathcal{N}_2(\boldsymbol{\mu}_A, \Sigma_A) \quad \text{y} \quad p(\mathbf{x} | B) \sim \mathcal{N}_2(\boldsymbol{\mu}_B, \Sigma_B)$$

Para cada uno de los casos de abajo:

- Calcula funciones discriminantes para  $A$  y  $B$
- Calcula la frontera de decisión para el clasificador

	$\boldsymbol{\mu}_A$	$\Sigma_A$	$\boldsymbol{\mu}_B$	$\Sigma_B$		$\boldsymbol{\mu}_A$	$\Sigma_A$	$\boldsymbol{\mu}_B$	$\Sigma_B$
<b>1</b>	$\begin{pmatrix} 3 \\ 0 \end{pmatrix}$	$\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$	$\begin{pmatrix} 0 \\ 3 \end{pmatrix}$	$\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$	<b>4</b>	$\begin{pmatrix} 0 \\ 0 \end{pmatrix}$	$\begin{pmatrix} 1/8 & 0 \\ 0 & 1/4 \end{pmatrix}$	$\begin{pmatrix} 0 \\ 2 \end{pmatrix}$	$\begin{pmatrix} 1/4 & 0 \\ 0 & 1/2 \end{pmatrix}$
<b>2</b>	$\begin{pmatrix} 2 \\ 7 \end{pmatrix}$	$\begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}$	$\begin{pmatrix} 4 \\ 9 \end{pmatrix}$	$\begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix}$	<b>5</b>	$\begin{pmatrix} 0 \\ 0 \end{pmatrix}$	$\begin{pmatrix} 1/2 & 0 \\ 0 & 1/8 \end{pmatrix}$	$\begin{pmatrix} 0 \\ 2 \end{pmatrix}$	$\begin{pmatrix} 1/4 & 0 \\ 0 & 1/2 \end{pmatrix}$
<b>3</b>	$\begin{pmatrix} 0 \\ 0 \end{pmatrix}$	$\begin{pmatrix} 1 & 2 \\ 2 & 5 \end{pmatrix}$	$\begin{pmatrix} 0 \\ 4 \end{pmatrix}$	$\begin{pmatrix} 1 & 2 \\ 2 & 5 \end{pmatrix}$	<b>6</b>	$\begin{pmatrix} 0 \\ 0 \end{pmatrix}$	$\begin{pmatrix} 1/8 & 0 \\ 0 & 1/2 \end{pmatrix}$	$\begin{pmatrix} 0 \\ 2 \end{pmatrix}$	$\begin{pmatrix} 1/4 & 0 \\ 0 & 1/2 \end{pmatrix}$
					<b>7</b>	$\begin{pmatrix} 0 \\ 0 \end{pmatrix}$	$\begin{pmatrix} 1/4 & 0 \\ 0 & 1/4 \end{pmatrix}$	$\begin{pmatrix} 0 \\ 2 \end{pmatrix}$	$\begin{pmatrix} 1/4 & 0 \\ 0 & 1/2 \end{pmatrix}$

17. Tenemos  $N = 6$  vectores reales bidimensionales extraídos aleatoriamente de  $C = 2$  distribuciones gaussianas con matriz de covarianza común:

$n$	1	2	3	4	5	6
$x_{n1}$	3	3	6	6	9	9
$x_{n2}$	3	9	6	3	6	0
$c_n$	1	1	1	2	2	2

- a) Calcula el clasificador gaussiano más probable respecto a estos datos  
b) Calcula la frontera de decisión del clasificador anterior  
c) Clasifica los puntos  $\begin{pmatrix} 3 \\ 6 \end{pmatrix}$  y  $\begin{pmatrix} 9 \\ 3 \end{pmatrix}$
18. Tenemos  $N = 10$  valores reales extraídos aleatoriamente de  $C = 2$  distribuciones gaussianas:

$$(1.0, A), (1.2, A), (1.3, A), (1.1, A), (0.9, A) \\ (1.3, B), (1.2, B), (1.4, B), (1.2, B), (1.3, B)$$

Se pide:

- a) Calcula el clasificador gaussiano más probable respecto a estos datos
- b) Calcula la frontera de decisión del clasificador anterior
- c) Clasifica el punto  $x = 1.15$  suponiendo que ambas clases son equiprobables

19. Sean  $A$ ,  $B$  y  $C$  tres clases con igual probabilidad *a priori* y f.d. condicional de clase gaussianas gobernadas por sus parámetros

$$\mu_A = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \quad \Sigma_A = \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & 1 \end{pmatrix} \quad \mu_B = \begin{pmatrix} \frac{1}{2} \\ 1 \end{pmatrix} \quad \Sigma_B = \begin{pmatrix} \frac{1}{4} & 0 \\ 0 & \frac{1}{2} \end{pmatrix} \quad \mu_C = \begin{pmatrix} 0 \\ \frac{3}{4} \end{pmatrix} \quad \Sigma_C = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}$$

Calcula  $p(\mathbf{x} | A)$ ,  $p(\mathbf{x} | B)$  y  $p(\mathbf{x} | C)$  para  $\mathbf{x} = \begin{pmatrix} 3/4 \\ 5/4 \end{pmatrix}$

20. Se tiene un clasificador en dos clases basado en distribuciones gaussianas unidimensionales, de forma que para la clase 1 se tiene  $\mu_1 = 0$ ,  $\sigma_1 = 2$ , y para la clase 2 se tiene  $\mu_2 = 1$ ,  $\sigma_2 = 1$ . Se pide clasificar el punto  $y = 0.5$  empleando  $\arg \max P(c|y)$  teniendo probabilidades *a priori* idénticas para ambas clases.
21. Se definen las clases  $A$  y  $B$  en un espacio bidimensional; cada clase está modelada respectivamente por una gaussiana, de forma que sus parámetros son:

$$\mu_A = \begin{pmatrix} 1 & 1 \end{pmatrix}^t \quad \Sigma_A = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} \quad \mu_B = \begin{pmatrix} 0 & -1 \end{pmatrix}^t \quad \Sigma_B = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix}$$

Sabiendo que las probabilidades *a priori* de cada clase son  $P(A) = 0.4$  y  $P(B) = 0.6$ , clasifica la muestra  $\mathbf{x} = \begin{pmatrix} 1 & -1 \end{pmatrix}^t$ .

22. Sea  $A$ ,  $B$  y  $C$  tres clases con probabilidades *a priori*  $p(A) = 1/2$  y  $p(B) = p(C) = 1/4$ , y f.d.p. condicionales de clase gaussianas  $p(\mathbf{x} | A) \sim \mathcal{N}_2(\mu_A, \Sigma_A)$ ,  $p(\mathbf{x} | B) \sim \mathcal{N}_2(\mu_B, \Sigma_B)$  y  $p(\mathbf{x} | C) \sim \mathcal{N}_2(\mu_C, \Sigma_C)$

$$\mu_A = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \Sigma_A = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \quad \mu_B = \begin{pmatrix} 2 \\ 2 \end{pmatrix} \quad \Sigma_B = \begin{pmatrix} 1 & -1 \\ -1 & 2 \end{pmatrix} \quad \mu_C = \begin{pmatrix} -2 \\ -2 \end{pmatrix} \quad \Sigma_C = \begin{pmatrix} 1 & -1 \\ -1 & 2 \end{pmatrix}$$

- a) Calcula funciones discriminantes para  $A$ ,  $B$  y  $C$
- b) Calcula la frontera de decisión entre las clases  $A$  y  $B$
- c) Calcula la frontera de decisión entre las clases  $B$  y  $C$
- d) Clasifica la muestra  $\mathbf{y} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$

Nota:  $\Sigma_A^{-1} = \begin{pmatrix} 1/2 & 0 \\ 0 & 1/2 \end{pmatrix}$  y  $\Sigma_B^{-1} = \Sigma_C^{-1} = \begin{pmatrix} 2 & 1 \\ 1 & 1 \end{pmatrix}$

23. Sea  $A$  y  $B$  dos clases con probabilidades *a priori*  $p(A) = 1/2$  y  $p(B) = 1/2$ , y f.d.p. condicionales de clase gaussianas  $p(\mathbf{x} | A) \sim \mathcal{N}_2(\mu_A, \Sigma_A)$  y  $p(\mathbf{x} | B) \sim \mathcal{N}_2(\mu_B, \Sigma_B)$

$$\mu_A = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \Sigma_A = \begin{pmatrix} 1/2 & 0 \\ 0 & 2 \end{pmatrix} \quad \mu_B = \begin{pmatrix} 0 \\ 1 \end{pmatrix} \quad \Sigma_B = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}$$

- a) Calcula funciones discriminantes para  $A$  y  $B$
- b) Calcula la frontera de decisión entre las clases  $A$  y  $B$
- c) Representa gráficamente la frontera y las regiones de decisión
- d) Se desea suavizar las matrices de covarianza de ambas clases mediante *flat smoothing*. Calcula el valor de  $\alpha$  necesario para que el clasificador resultante sea lineal

Nota:  $\Sigma_A^{-1} = \begin{pmatrix} 2 & 0 \\ 0 & 1/2 \end{pmatrix}$  y  $\Sigma_B^{-1} = \begin{pmatrix} 1 & 0 \\ 0 & 1/2 \end{pmatrix}$

24. Sea  $A$  y  $B$  dos clases con probabilidades *a priori*  $p(A) = 1/4$  y  $p(B) = 3/4$ , y f.d.p. condicionales de clase gaussianas  $p(\mathbf{x} | A) \sim \mathcal{N}_2(\mu_A, \Sigma_A)$  y  $p(\mathbf{x} | B) \sim \mathcal{N}_2(\mu_B, \Sigma_B)$

$$\mu_A = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \quad \Sigma_A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \quad \mu_B = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \quad \Sigma_B = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

- a)* Calcula funciones discriminantes para  $A$  y  $B$
- b)* Calcula la frontera de decisión entre las clases  $A$  y  $B$
- c)* Representa gráficamente la frontera y las regiones de decisión


## Soluciones

1. a)

$$g_A(\mathbf{x}) = \frac{1}{2} \left(\frac{1}{2}\right)^{x_1} \left(\frac{1}{2}\right)^{1-x_1} \left(\frac{1}{2}\right)^{x_2} \left(\frac{1}{2}\right)^{1-x_2} \quad g_B(\mathbf{x}) = \frac{1}{2} \left(\frac{3}{4}\right)^{x_1} \left(\frac{1}{4}\right)^{1-x_1} \left(\frac{1}{4}\right)^{x_2} \left(\frac{3}{4}\right)^{1-x_2}$$

Si tuvieramos que calcular la frontera de decisión entre la clase A y B, es más sencillo hacerlo para los clasificadores equivalentes usando  $\log_2$ :

$$\begin{aligned} \log_2 g_A(\mathbf{x}) &= \log_2 g_B(\mathbf{x}) \\ -1 - x_1 - (1 - x_1) - x_2 - (1 - x_2) &= -1 + x_1 \log_2 \frac{3}{4} + (1 - x_1) \log_2 \frac{1}{4} + x_2 \log_2 \frac{1}{4} + (1 - x_2) \log_2 \frac{3}{4} \\ -3 &= -1 + x_1(\log_2 3 - 2) - 2(1 - x_1) - 2x_2 + (1 - x_2)(\log_2 3 - 2) \\ -3 &= -1 + x_1 \log_2 3 - 2 - 2x_2 + \log_2 3 - 2 - x_2 \log_2 3 + 2x_2 \\ -3 &= -5 + \log_2 3 + x_1 \log_2 3 - x_2 \log_2 3 \\ x_2 &= \frac{-2 + \log_2 3}{\log_2 3} + x_1 = -0.26 + x_1 \end{aligned}$$



b) En general, el error global  $p(e)$  se calcula como

$$p(e) = \sum_{\mathbf{x}} p(\mathbf{x}, e) = \sum_{\mathbf{x}} p(\mathbf{x}) p(e | \mathbf{x}) = \sum_{\mathbf{x}} p(\mathbf{x}) \left(1 - \max_c p(c | \mathbf{x})\right).$$

Aplicamos Bayes y simplificamos la expresión teniendo en cuenta que sólo tenemos dos clases

$$\begin{aligned} p(e) &= \sum_{\mathbf{x}} p(\mathbf{x}) \min_c p(c | \mathbf{x}) = \sum_{\mathbf{x}} p(\mathbf{x}) \min_c \frac{p(c) p(\mathbf{x} | c)}{p(\mathbf{x})} = \sum_{\mathbf{x}} \min_c p(c) p(\mathbf{x} | c) \\ &= \sum_{\mathbf{x}} \min_c p(c) \prod_d p_{cd}^{x_d} (1 - p_{cd})^{(1-x_d)} \\ &= \sum_{\mathbf{x}} \min \left( \frac{1}{2} \cdot \frac{1}{2} \left(1 - \frac{1}{2}\right)^{(1-x_1)} \cdot \frac{1}{2} \left(1 - \frac{1}{2}\right)^{(1-x_2)}, \frac{1}{2} \cdot \frac{3}{4} \left(1 - \frac{3}{4}\right)^{(1-x_1)} \cdot \frac{1}{4} \left(1 - \frac{1}{4}\right)^{(1-x_2)} \right) \\ &= 0.34375 \end{aligned}$$

$$\text{donde } \mathbf{x} \in \left\{ \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \end{pmatrix} \right\}$$

2. a)

$$g_1(\mathbf{x}) = \frac{1}{2} \left(\frac{2}{3}\right)^{x_1} \left(\frac{1}{3}\right)^{1-x_1} \left(\frac{1}{3}\right)^{x_2} \left(\frac{2}{3}\right)^{1-x_2} \quad g_2(\mathbf{x}) = \frac{1}{2} \left(\frac{1}{3}\right)^{x_1} \left(\frac{2}{3}\right)^{1-x_1} \left(\frac{1}{3}\right)^{x_2} \left(\frac{2}{3}\right)^{1-x_2}$$

b)

$$g_1(\mathbf{x}) = \frac{1}{2} \left(\frac{2}{3}\right)^{x_1} \left(\frac{1}{3}\right)^{1-x_1} \quad g_2(\mathbf{x}) = \frac{1}{2} \left(\frac{1}{3}\right)^{x_1} \left(\frac{2}{3}\right)^{1-x_1}$$

c) Son equivalentes

3. a)

$$g_1(\mathbf{x}) = \frac{1}{2} (1)^{x_1} (0)^{1-x_1} \left(\frac{2}{3}\right)^{x_2} \left(\frac{1}{3}\right)^{1-x_2} \left(\frac{1}{2}\right)^{x_3} \left(\frac{1}{2}\right)^{1-x_3}$$

$$g_2(\mathbf{x}) = \frac{1}{2} \left(\frac{2}{3}\right)^{x_1} \left(\frac{1}{3}\right)^{1-x_1} \left(\frac{1}{3}\right)^{x_2} \left(\frac{2}{3}\right)^{1-x_2} (0)^{x_3} (1)^{1-x_3}$$

b) Ambas F.D. dan valor 0, no es posible clasificar.

c)

$$\tilde{\mathbf{p}}_1 = \left(\frac{9}{10}, \frac{2}{3}, \frac{1}{2}\right)^t \quad \tilde{\mathbf{p}}_2 = \left(\frac{2}{3}, \frac{1}{3}, \frac{1}{10}\right)^t$$

d)

$$\tilde{\mathbf{p}}_1 = \left(\frac{7}{8}, \frac{5}{8}, \frac{1}{2}\right)^t \quad \tilde{\mathbf{p}}_2 = \left(\frac{5}{8}, \frac{3}{8}, \frac{1}{8}\right)^t$$

4. (Examen Recuperación Primer Parcial 2013)

$$\hat{c}(\mathbf{y}) = \arg \max_c P(c | \mathbf{y}) \approx \arg \max_c p(\mathbf{y} | c) p(c)$$

Para la clase 1:

$$\begin{aligned} p(\mathbf{y} = (0 \ 1)^t | c = 1) &= (p_{11} y_1 + (1 - p_{11})(1 - y_1)) \cdot (p_{12} y_2 + (1 - p_{12})(1 - y_2)) \\ &= (0.3 \cdot 0 + (1 - 0.3) \cdot (1 - 0)) \cdot (0.2 \cdot 1 + (1 - 0.2) \cdot (1 - 1)) \\ &= 0.14 \end{aligned}$$

Para la clase 2:

$$\begin{aligned} p(\mathbf{y} = (0 \ 1)^t | c = 2) &= (p_{21} y_1 + (1 - p_{21})(1 - y_1)) \cdot (p_{22} y_2 + (1 - p_{22})(1 - y_2)) \\ &= (0.6 \cdot 0 + (1 - 0.6)(1 - 0)) \cdot (0.8 \cdot 1 + (1 - 0.8) \cdot (1 - 1)) \\ &= 0.32 \end{aligned}$$

Dado que  $p(c = 1) = p(c = 2) = 0.5$ , la muestra  $\mathbf{y}$  se clasifica en la clase 2.



5. (Examen Recuperación Segundo Parcial 2013)

a)

$$p(1) = p(2) = p(3) = \frac{1}{3}$$

$$\hat{\mathbf{p}}_1 = \frac{1}{4} \begin{pmatrix} 1+1+1+1 \\ 0+0+0+0 \\ 1+0+1+0 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 1/2 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \frac{1}{4} \begin{pmatrix} 0+0+0+0 \\ 1+1+0+1 \\ 1+1+1+1 \end{pmatrix} = \begin{pmatrix} 0 \\ 3/4 \\ 1 \end{pmatrix}$$

$$\hat{\mathbf{p}}_3 = \frac{1}{4} \begin{pmatrix} 0+1+1+0 \\ 1+1+1+1 \\ 0+0+0+0 \end{pmatrix} = \begin{pmatrix} 1/2 \\ 1 \\ 0 \end{pmatrix}$$

b)

$$\hat{\mathbf{p}}_1 = \begin{pmatrix} 1 \\ 0 \\ 1/2 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_1 = \begin{pmatrix} 7/8 \\ 1/8 \\ 1/2 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \begin{pmatrix} 0 \\ 3/4 \\ 1 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_2 = \begin{pmatrix} 1/8 \\ 3/4 \\ 7/8 \end{pmatrix}$$

$$\hat{\mathbf{p}}_3 = \begin{pmatrix} 1/2 \\ 1 \\ 0 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_3 = \begin{pmatrix} 1/2 \\ 7/8 \\ 1/8 \end{pmatrix}$$

En nuestro caso, dado que las priors son idénticas, la regla de clasificación se reduce a:

$$p(\mathbf{y} = (0 \ 0 \ 1) \mid c = 1) = (7/8)^0(1 - 7/8)^{(1-0)}(1/8)^0(1 - 1/8)^{(1-0)}(1/2)^1(1 - 1/2)^{(1-1)} = 1/8 \cdot 7/8 \cdot 1/2 = \frac{7}{128}$$

$$p(\mathbf{y} = (0 \ 0 \ 1) \mid c = 2) = (1/8)^0(1 - 1/8)^{(1-0)}(3/4)^0(1 - 3/4)^{(1-0)}(7/8)^1(1 - 7/8)^{(1-1)} = 7/8 \cdot 1/4 \cdot 7/8 = \frac{49}{256}$$

$$p(\mathbf{y} = (0 \ 0 \ 1) \mid c = 3) = (1/2)^0(1 - 1/2)^{(1-0)}(7/8)^0(1 - 7/8)^{(1-0)}(1/8)^1(1 - 1/8)^{(1-1)} = 1/2 \cdot 1/8 \cdot 1/8 = \frac{1}{128}$$

La muestra  $\mathbf{y}$  se clasifica en la clase 2.

6. (Examen Recuperación Segundo Parcial 2014)

a)

$$p(1) = p(2) = \frac{6}{12} = 0.5$$

$$\hat{\mathbf{p}}_1 = \frac{1}{6} \begin{pmatrix} 1+0+1+1+0+1 \\ 0+1+1+1+0+1 \\ 0+0+0+0+0+0 \\ 0+0+0+0+0+0 \end{pmatrix} = \frac{1}{6} \begin{pmatrix} 4 \\ 4 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 2/3 \\ 2/3 \\ 0.0 \\ 0.0 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \frac{1}{6} \begin{pmatrix} 0+0+0+0+0+0 \\ 0+0+0+0+0+0 \\ 1+1+0+1+0+1 \\ 1+1+1+1+1+1 \end{pmatrix} = \frac{1}{6} \begin{pmatrix} 0 \\ 0 \\ 4 \\ 6 \end{pmatrix} = \begin{pmatrix} 0.0 \\ 0.0 \\ 2/3 \\ 1.0 \end{pmatrix}$$

b)

$$\hat{\mathbf{p}}_1 = \begin{pmatrix} 2/3 \\ 2/3 \\ 0.0 \\ 0.0 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_1 = \begin{pmatrix} 2/3 \\ 2/3 \\ 1/3 \\ 1/3 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 \\ 0.0 \\ 2/3 \\ 1.0 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_2 = \begin{pmatrix} 1/3 \\ 1/3 \\ 2/3 \\ 2/3 \end{pmatrix}$$

7. (Examen Recuperación Segundo Parcial 2015)

a)

$$p(1) = \frac{3}{9} = \frac{1}{3} \quad p(2) = \frac{6}{9} = \frac{2}{3}$$

$$\hat{\mathbf{p}}_1 = \frac{1}{3} \begin{pmatrix} 1+0+0 \\ 0+0+1 \end{pmatrix} = \frac{1}{3} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{1}{3} \\ \frac{1}{3} \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \frac{1}{6} \begin{pmatrix} 1+1+1+1+1+0 \\ 0+0+0+0+0+1 \end{pmatrix} = \frac{1}{6} \begin{pmatrix} 5 \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{5}{6} \\ \frac{1}{6} \end{pmatrix}$$

b) En general, el error global  $p(e)$  se calcula como

$$p(e) = \sum_{\mathbf{x}} p(\mathbf{x}, e) = \sum_{\mathbf{x}} p(\mathbf{x}) p(e | \mathbf{x}) = \sum_{\mathbf{x}} p(\mathbf{x}) \left( 1 - \max_c p(c | \mathbf{x}) \right).$$

Aplicamos Bayes y simplificamos la expresión teniendo en cuenta que sólo tenemos dos clases

$$p(e) = \sum_{\mathbf{x}} p(\mathbf{x}) \min_c p(c | \mathbf{x}) = \sum_{\mathbf{x}} p(\mathbf{x}) \min_c \frac{p(c) p(\mathbf{x} | c)}{p(\mathbf{x})} = \sum_{\mathbf{x}} \min_c p(c) p(\mathbf{x} | c) = \sum_{\mathbf{x}} \min_c p(c) \prod_d p_{cd}^{x_d} (1 - p_{cd})^{(1-x_d)}$$

$$= \sum_{\mathbf{x}} \min \left( \frac{1}{3} \cdot \frac{1}{3}^{x_1} \left( 1 - \frac{1}{3} \right)^{(1-x_1)} \cdot \frac{1}{3}^{x_2} \left( 1 - \frac{1}{3} \right)^{(1-x_2)}, \frac{2}{3} \cdot \frac{5}{6}^{x_1} \left( 1 - \frac{5}{6} \right)^{(1-x_1)} \cdot \frac{1}{6}^{x_2} \left( 1 - \frac{1}{6} \right)^{(1-x_2)} \right)$$

$\mathbf{x}$		$p(c) p(\mathbf{x}   c)$		
$x_1$	$x_2$	$c = 1$	$c = 2$	$\min_c$
0	0	$\frac{1}{3} \cdot \frac{2}{3} \cdot \frac{2}{3}$	$\frac{2}{3} \cdot \frac{1}{6} \cdot \frac{5}{6}$	$\frac{10}{108}$
0	1	$\frac{1}{3} \cdot \frac{2}{3} \cdot \frac{1}{3}$	$\frac{2}{3} \cdot \frac{1}{6} \cdot \frac{1}{6}$	$\frac{2}{108}$
1	0	$\frac{1}{3} \cdot \frac{1}{3} \cdot \frac{2}{3}$	$\frac{2}{3} \cdot \frac{5}{6} \cdot \frac{5}{6}$	$\frac{2}{27}$
1	1	$\frac{1}{3} \cdot \frac{1}{3} \cdot \frac{1}{3}$	$\frac{2}{3} \cdot \frac{5}{6} \cdot \frac{1}{6}$	$\frac{1}{27}$

Sumando el mínimo de  $p(c) p(\mathbf{x} | c)$  para cada  $\mathbf{x}$ :

$$p(e) = \frac{10}{108} + \frac{2}{108} + \frac{2}{27} + \frac{1}{27} = \frac{2}{9}$$

c)

$$\tilde{\mathbf{p}}_1 = \begin{pmatrix} \frac{1}{3} \\ \frac{1}{3} \end{pmatrix}$$

$$\tilde{\mathbf{p}}_2 = \begin{pmatrix} \frac{3}{4} \\ \frac{1}{4} \end{pmatrix}$$

d) Aplicamos la regla de clasificación de Bayes:

$$\hat{c}(\mathbf{y}) = \arg \max_c p(c) p(\mathbf{y} | c) = p(c) \prod_d p_{cd}^{y_d} (1 - p_{cd})^{(1-y_d)}$$

$$p(c=1) p(\mathbf{y} = (1 \ 1)^t | c=1) = \frac{1}{3} \cdot \frac{1}{3} \left(1 - \frac{1}{3}\right)^{(1-y_1)} \cdot \frac{1}{3} \left(1 - \frac{1}{3}\right)^{(1-y_2)} = \frac{1}{3} \cdot \frac{1}{3} \cdot \frac{1}{3} = \frac{1}{27}$$

$$p(c=2) p(\mathbf{y} = (1 \ 1)^t | c=2) = \frac{2}{3} \cdot \frac{3}{4} \left(1 - \frac{3}{4}\right)^{(1-y_1)} \cdot \frac{1}{4} \left(1 - \frac{1}{4}\right)^{(1-y_2)} = \frac{2}{3} \cdot \frac{3}{4} \cdot \frac{1}{4} = \frac{1}{8}$$

La muestra  $\mathbf{y}$  se clasifica en la clase 2.

8. a)

$$g_A(\mathbf{x}) = \left(\frac{1}{2}\right)^{x_1} \left(\frac{1}{2}\right)^{x_2} \quad g_B(\mathbf{x}) = \left(\frac{3}{4}\right)^{x_1} \left(\frac{1}{4}\right)^{x_2}$$

b)  $p(\text{err}) = \frac{568}{2048} \approx 0.2773$

9. a)

$$\hat{\mathbf{p}}_1 = \begin{pmatrix} \frac{3}{4} \\ \frac{1}{4} \end{pmatrix} \quad \hat{\mathbf{p}}_2 = \begin{pmatrix} \frac{1}{2} \\ \frac{1}{2} \end{pmatrix}$$

b)

$x^t$	(0,4)	(1,3)	(2,2)	(3,1)	(4,0)
$p(1 \mathbf{x})$	$\frac{1}{17}$	$\frac{12}{76}$	$\frac{54}{150}$	$\frac{108}{172}$	$\frac{81}{97}$
$p(2 \mathbf{x})$	$\frac{16}{17}$	$\frac{64}{76}$	$\frac{96}{150}$	$\frac{64}{172}$	$\frac{16}{97}$

10. a)

$$g_1(\mathbf{x}) = \left(\frac{1}{10}\right)^{x_1} \left(\frac{3}{10}\right)^{x_2} \left(\frac{1}{10}\right)^{x_3} \left(\frac{1}{2}\right)^{x_4} (0)^{x_5}$$

$$g_2(\mathbf{x}) = \left(\frac{3}{10}\right)^{x_1} \left(\frac{1}{5}\right)^{x_2} \left(\frac{2}{5}\right)^{x_3} (0)^{x_4} \left(\frac{1}{10}\right)^{x_5}$$

$$g_3(\mathbf{x}) = \left(\frac{1}{5}\right)^{x_1} (0)^{x_2} \left(\frac{1}{2}\right)^{x_3} (0)^{x_4} \left(\frac{3}{10}\right)^{x_5}$$

b) Todas las F.D. dan valor 0, no es posible clasificar.

c)

$$\tilde{\mathbf{p}}_1 = \left(\frac{2}{15}, \frac{4}{15}, \frac{2}{15}, \frac{2}{5}, \frac{1}{15}\right)^t \quad \tilde{\mathbf{p}}_2 = \left(\frac{4}{15}, \frac{1}{5}, \frac{1}{3}, \frac{1}{15}, \frac{2}{15}\right)^t \quad \tilde{\mathbf{p}}_3 = \left(\frac{1}{5}, \frac{1}{15}, \frac{2}{5}, \frac{1}{15}, \frac{4}{15}\right)^t$$

d)

$$\tilde{\mathbf{p}}_1 = \left(\frac{1}{20}, \frac{1}{4}, \frac{1}{20}, \frac{9}{20}, \frac{1}{5}\right)^t \quad \tilde{\mathbf{p}}_2 = \left(\frac{1}{4}, \frac{3}{20}, \frac{7}{20}, \frac{1}{5}, \frac{1}{20}\right)^t \quad \tilde{\mathbf{p}}_3 = \left(\frac{3}{20}, \frac{3}{40}, \frac{9}{20}, \frac{3}{40}, \frac{1}{4}\right)^t$$

e)

$$\tilde{\mathbf{p}}_1 = \left(\frac{9}{100}, \frac{29}{100}, \frac{9}{100}, \frac{49}{100}, \frac{4}{100}\right)^t \quad \tilde{\mathbf{p}}_2 = \left(\frac{29}{100}, \frac{19}{100}, \frac{39}{100}, \frac{4}{100}, \frac{9}{100}\right)^t \quad \tilde{\mathbf{p}}_3 = \left(\frac{18}{100}, \frac{3}{100}, \frac{48}{100}, \frac{3}{100}, \frac{28}{100}\right)^t$$

11. (Segundo Parcial Junio 2013)

a)

$$\hat{\mathbf{p}}_1 = \begin{pmatrix} 0.5 \\ 0.3 \\ 0.2 \\ 0.0 \\ 0.0 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_1 = \frac{1}{1.5} \begin{pmatrix} 0.5 + 0.1 \\ 0.3 + 0.1 \\ 0.2 + 0.1 \\ 0.0 + 0.1 \\ 0.0 + 0.1 \end{pmatrix} = \frac{1}{1.5} \begin{pmatrix} 0.6 \\ 0.4 \\ 0.3 \\ 0.1 \\ 0.1 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 \\ 0.0 \\ 0.3 \\ 0.3 \\ 0.4 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_2 = \frac{1}{1.5} \begin{pmatrix} 0.0 + 0.1 \\ 0.0 + 0.1 \\ 0.3 + 0.1 \\ 0.3 + 0.1 \\ 0.4 + 0.1 \end{pmatrix} = \frac{1}{1.5} \begin{pmatrix} 0.1 \\ 0.1 \\ 0.4 \\ 0.4 \\ 0.5 \end{pmatrix}$$

En nuestro caso, dado que las priors son idénticas, la regla de clasificación se reduce a:

$$p(\mathbf{y} = (1 \ 1 \ 1 \ 1 \ 1) \mid c = 1) = \frac{0.6}{1.5} \cdot \frac{0.4}{1.5} \cdot \frac{0.3}{1.5} \cdot \frac{0.1}{1.5} \cdot \frac{0.1}{1.5} = 0.00009$$

$$p(\mathbf{y} = (1 \ 1 \ 1 \ 1 \ 1) \mid c = 2) = \frac{0.1}{1.5} \cdot \frac{0.1}{1.5} \cdot \frac{0.4}{1.5} \cdot \frac{0.4}{1.5} \cdot \frac{0.5}{1.5} = 0.0001$$

La muestra  $\mathbf{y}$  se clasifica en la clase 2.

b)

$$\hat{\mathbf{p}}_1 = \begin{pmatrix} 0.5 \\ 0.3 \\ 0.2 \\ 0.0 \\ 0.0 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_1 = \begin{pmatrix} 0.5 - 0.05 \\ 0.3 - 0.05 \\ 0.2 - 0.05 \\ 0.0 + \frac{1}{2} \cdot 0.15 \\ 0.0 + \frac{1}{2} \cdot 0.15 \end{pmatrix} = \begin{pmatrix} 0.45 \\ 0.25 \\ 0.15 \\ 0.075 \\ 0.075 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 \\ 0.0 \\ 0.3 \\ 0.3 \\ 0.4 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 + \frac{1}{2} \cdot 0.15 \\ 0.0 + \frac{1}{2} \cdot 0.15 \\ 0.3 - 0.05 \\ 0.3 - 0.05 \\ 0.4 - 0.05 \end{pmatrix} = \begin{pmatrix} 0.075 \\ 0.075 \\ 0.25 \\ 0.25 \\ 0.35 \end{pmatrix}$$

$$p(\mathbf{y} = (1 \ 1 \ 1 \ 1 \ 1) \mid c = 1) = 0.45 \cdot 0.25 \cdot 0.15 \cdot 0.075 \cdot 0.075 = 0.00009$$

$$p(\mathbf{y} = (1 \ 1 \ 1 \ 1 \ 1) \mid c = 2) = 0.075 \cdot 0.075 \cdot 0.25 \cdot 0.25 \cdot 0.35 = 0.0001$$

La muestra  $\mathbf{y}$  se clasifica en la clase 2.

12. (Segundo Parcial Junio 2014)

a)

$$p(1) = p(2) = \frac{6}{12} = 0.5$$

$$\hat{\mathbf{p}}_1 = \frac{1}{20} \begin{pmatrix} 1 + 2 + 1 + 1 + 2 + 1 \\ 2 + 1 + 0 + 1 + 2 + 0 \\ 0 + 0 + 0 + 0 + 0 + 0 \\ 1 + 0 + 2 + 1 + 0 + 2 \\ 0 + 0 + 0 + 0 + 0 + 0 \end{pmatrix} = \frac{1}{20} \begin{pmatrix} 8 \\ 6 \\ 0 \\ 6 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.4 \\ 0.3 \\ 0.0 \\ 0.3 \\ 0.0 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \frac{1}{20} \begin{pmatrix} 0 + 0 + 0 + 0 + 0 + 0 \\ 0 + 0 + 0 + 0 + 0 + 0 \\ 1 + 1 + 0 + 1 + 0 + 1 \\ 1 + 2 + 1 + 1 + 2 + 1 \\ 1 + 3 + 1 + 1 + 1 + 1 \end{pmatrix} = \frac{1}{20} \begin{pmatrix} 0 \\ 0 \\ 4 \\ 8 \\ 8 \end{pmatrix} = \begin{pmatrix} 0.0 \\ 0.0 \\ 0.2 \\ 0.4 \\ 0.4 \end{pmatrix}$$

b)

$$\hat{\mathbf{p}}_1 = \begin{pmatrix} 0.4 \\ 0.3 \\ 0.0 \\ 0.3 \\ 0.0 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_1 = \frac{1}{2.0} \begin{pmatrix} 0.4 + 0.2 \\ 0.3 + 0.2 \\ 0.0 + 0.2 \\ 0.3 + 0.2 \\ 0.0 + 0.2 \end{pmatrix} = \begin{pmatrix} 0.30 \\ 0.25 \\ 0.10 \\ 0.25 \\ 0.10 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 \\ 0.0 \\ 0.2 \\ 0.4 \\ 0.4 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_2 = \frac{1}{2.0} \begin{pmatrix} 0.0 + 0.2 \\ 0.0 + 0.2 \\ 0.2 + 0.2 \\ 0.4 + 0.2 \\ 0.4 + 0.2 \end{pmatrix} = \begin{pmatrix} 0.10 \\ 0.10 \\ 0.20 \\ 0.30 \\ 0.30 \end{pmatrix}$$

c)

$$\hat{\mathbf{p}}_1 = \begin{pmatrix} 0.4 \\ 0.3 \\ 0.0 \\ 0.3 \\ 0.0 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_1 = \begin{pmatrix} 0.4 - 0.1 + \frac{1}{5} \cdot 0.3 \\ 0.3 - 0.1 + \frac{1}{5} \cdot 0.3 \\ 0.0 + \frac{1}{5} \cdot 0.3 \\ 0.3 - 0.1 + \frac{1}{5} \cdot 0.3 \\ 0.0 + \frac{1}{5} \cdot 0.3 \end{pmatrix} = \begin{pmatrix} 0.36 \\ 0.26 \\ 0.06 \\ 0.26 \\ 0.06 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 \\ 0.0 \\ 0.2 \\ 0.4 \\ 0.4 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 + \frac{1}{5} \cdot 0.3 \\ 0.0 + \frac{1}{5} \cdot 0.3 \\ 0.2 - 0.1 + \frac{1}{5} \cdot 0.3 \\ 0.4 - 0.1 + \frac{1}{5} \cdot 0.3 \\ 0.4 - 0.1 + \frac{1}{5} \cdot 0.3 \end{pmatrix} = \begin{pmatrix} 0.06 \\ 0.06 \\ 0.16 \\ 0.36 \\ 0.36 \end{pmatrix}$$

d)

$$\hat{\mathbf{p}}_1 = \begin{pmatrix} 0.4 \\ 0.3 \\ 0.0 \\ 0.3 \\ 0.0 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_1 = \begin{pmatrix} 0.4 - 0.1 + 0.1 \cdot 0.3 \\ 0.3 - 0.1 + 0.2 \cdot 0.3 \\ 0.0 + 0.4 \cdot 0.3 \\ 0.3 - 0.1 + 0.2 \cdot 0.3 \\ 0.0 + 0.1 \cdot 0.3 \end{pmatrix} = \begin{pmatrix} 0.33 \\ 0.26 \\ 0.12 \\ 0.26 \\ 0.03 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 \\ 0.0 \\ 0.2 \\ 0.4 \\ 0.4 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 + 0.1 \cdot 0.3 \\ 0.0 + 0.2 \cdot 0.3 \\ 0.2 - 0.1 + 0.4 \cdot 0.3 \\ 0.4 - 0.1 + 0.2 \cdot 0.3 \\ 0.4 - 0.1 + 0.1 \cdot 0.3 \end{pmatrix} = \begin{pmatrix} 0.03 \\ 0.06 \\ 0.22 \\ 0.36 \\ 0.33 \end{pmatrix}$$

e) En nuestro caso, dado que las priors son idénticas, la regla de clasificación se reduce a:

$$p(\mathbf{y} = (1 \ 1 \ 1 \ 1 \ 1) \mid c = 1) = 0.30 \cdot 0.25 \cdot 0.10 \cdot 0.25 \cdot 0.10 = 0.0001875$$

$$p(\mathbf{y} = (1 \ 1 \ 1 \ 1 \ 1) \mid c = 2) = 0.10 \cdot 0.10 \cdot 0.20 \cdot 0.30 \cdot 0.30 = 0.00018$$

La muestra  $\mathbf{y}$  se clasifica en la clase 1.

13. (Recuperación Segundo Parcial Junio 2014)

a)

$$p(1) = p(2) = \frac{6}{12} = 0.5$$

$$\hat{\mathbf{p}}_1 = \frac{1}{8} \begin{pmatrix} 1+0+1+1+0+1 \\ 0+1+1+1+0+1 \\ 0+0+0+0+0+0 \\ 0+0+0+0+0+0 \end{pmatrix} = \frac{1}{8} \begin{pmatrix} 4 \\ 4 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.5 \\ 0.5 \\ 0.0 \\ 0.0 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \frac{1}{10} \begin{pmatrix} 0+0+0+0+0+0 \\ 0+0+0+0+0+0 \\ 1+1+0+1+0+1 \\ 1+1+1+1+1+1 \end{pmatrix} = \frac{1}{10} \begin{pmatrix} 0 \\ 0 \\ 4 \\ 6 \end{pmatrix} = \begin{pmatrix} 0.0 \\ 0.0 \\ 0.4 \\ 0.6 \end{pmatrix}$$

b)

$$\hat{\mathbf{p}}_1 = \begin{pmatrix} 0.5 \\ 0.5 \\ 0.0 \\ 0.0 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_1 = \begin{pmatrix} 0.5 - 0.2 + \frac{1}{4} \cdot 0.4 \\ 0.5 - 0.2 + \frac{1}{4} \cdot 0.4 \\ 0.0 + \frac{1}{4} \cdot 0.4 \\ 0.0 + \frac{1}{4} \cdot 0.4 \end{pmatrix} = \begin{pmatrix} 0.4 \\ 0.4 \\ 0.1 \\ 0.1 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 \\ 0.0 \\ 0.4 \\ 0.6 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 + \frac{1}{4} \cdot 0.4 \\ 0.0 + \frac{1}{4} \cdot 0.4 \\ 0.4 - 0.2 + \frac{1}{4} \cdot 0.4 \\ 0.6 - 0.2 + \frac{1}{4} \cdot 0.4 \end{pmatrix} = \begin{pmatrix} 0.1 \\ 0.1 \\ 0.3 \\ 0.5 \end{pmatrix}$$

14. (Segundo Parcial Junio 2015)

a) Representando nuestros datos como vectores de contadores tenemos

	aa	bb	aa	ab	bc	ac
$x_a$	2	0	2	1	0	1
$x_b$	0	2	0	1	1	0
$x_c$	0	0	0	0	1	1
$c_n$	1	1	1	2	2	2

La estimación de los parámetros del clasificador multinomial es

$$p(1) = p(2) = \frac{3}{6} = \frac{1}{2}$$

$$\hat{\mathbf{p}}_1 = \frac{1}{6} \begin{pmatrix} 2+0+2 \\ 0+2+0 \\ 0+0+0 \end{pmatrix} = \frac{1}{6} \begin{pmatrix} 4 \\ 2 \\ 0 \end{pmatrix} = \begin{pmatrix} \frac{2}{3} \\ \frac{1}{3} \\ 0 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \frac{1}{6} \begin{pmatrix} 1+0+1 \\ 1+1+0 \\ 0+1+1 \end{pmatrix} = \frac{1}{6} \begin{pmatrix} 2 \\ 2 \\ 2 \end{pmatrix} = \begin{pmatrix} \frac{1}{3} \\ \frac{1}{3} \\ \frac{1}{3} \end{pmatrix}$$

b) En general, el error global  $p(e)$  se calcula como

$$p(e) = \sum_{\mathbf{x}} p(\mathbf{x}, e) = \sum_{\mathbf{x}} p(\mathbf{x}) p(e | \mathbf{x}) = \sum_{\mathbf{x}} p(\mathbf{x}) \left( 1 - \max_c p(c | \mathbf{x}) \right).$$

Como sólo tenemos dos clases con igual prior y aplicando Bayes

$$\begin{aligned}
p(e) &= \sum_{\mathbf{x}} p(\mathbf{x}) \min_c p(c | \mathbf{x}) = \sum_{\mathbf{x}} p(\mathbf{x}) \min_c \frac{p(c) p(\mathbf{x} | c)}{p(\mathbf{x})} = \sum_{\mathbf{x}} \min_c p(c) p(\mathbf{x} | c) \\
&= \frac{1}{2} \sum_{\mathbf{x}} \min_c p(\mathbf{x} | c) = \frac{1}{2} \sum_{\mathbf{x}} \frac{x_+!}{x_1! x_2! x_3!} \min (p_{1a}^{x_a} \cdot p_{1b}^{x_b} \cdot p_{1c}^{x_c}, p_{2a}^{x_a} \cdot p_{2b}^{x_b} \cdot p_{2c}^{x_c}) \\
&= \frac{1}{2} \sum_{\mathbf{x}} \frac{x_+!}{x_1! x_2! x_3!} \min \left( \left( \frac{2}{3} \right)^{x_a} \cdot \left( \frac{1}{3} \right)^{x_b} \cdot 0^{x_c}, \left( \frac{1}{3} \right)^{x_a} \cdot \left( \frac{1}{3} \right)^{x_b} \cdot \left( \frac{1}{3} \right)^{x_c} \right)
\end{aligned}$$

$\mathbf{x}$			$\frac{x_+!}{x_1! x_2! x_3!}$	$\prod_d p_{cd}^{x_d}$		
$x_a$	$x_b$	$x_c$		$c = 1$	$c = 2$	$\min_c$
0	0	2	1	0	$\frac{1}{9}$	0
0	2	0	1	$\frac{1}{9}$	$\frac{1}{9}$	$\frac{1}{9}$
2	0	0	1	$\frac{4}{9}$	$\frac{1}{9}$	$\frac{1}{9}$
0	1	1	2	0	$\frac{1}{9}$	0
1	0	1	2	0	$\frac{1}{9}$	0
1	1	0	2	$\frac{2}{9}$	$\frac{1}{9}$	$\frac{1}{9}$

Sumando para cada  $\mathbf{x}$ :

$$p(e) = \frac{1}{2} \left( 1 \cdot 0 + 1 \cdot \frac{1}{9} + 1 \cdot \frac{1}{9} + 2 \cdot 0 + 2 \cdot 0 + 2 \cdot \frac{1}{9} \right) = \frac{2}{9}$$

c)

$$\begin{aligned}
\hat{\mathbf{p}}_1 &= \frac{1}{2} \begin{pmatrix} \frac{2}{3} + \frac{1}{3} \\ \frac{1}{3} + \frac{1}{3} \\ 0 + \frac{1}{3} \end{pmatrix} = \begin{pmatrix} \frac{1}{2} \\ \frac{1}{3} \\ \frac{1}{6} \end{pmatrix} \\
\hat{\mathbf{p}}_2 &= \frac{1}{2} \begin{pmatrix} \frac{1}{3} + \frac{1}{3} \\ \frac{1}{3} + \frac{1}{3} \\ \frac{1}{3} + \frac{1}{3} \end{pmatrix} = \begin{pmatrix} \frac{1}{3} \\ \frac{1}{3} \\ \frac{1}{3} \end{pmatrix}
\end{aligned}$$

d) En nuestro caso, dado que las priors son idénticas, la regla de clasificación se reduce a:

$$\hat{c}(\mathbf{y}) = \arg \max_c p(\mathbf{y} | c) = \arg \max_c \prod_d p_{cd}^{y_d}$$

$$p(\mathbf{y} = (0 \ 0 \ 2)^t | c = 1) = \left( \frac{1}{2} \right)^0 \cdot \left( \frac{1}{3} \right)^0 \cdot \left( \frac{1}{6} \right)^2 = \frac{1}{36}$$

$$p(\mathbf{y} = (0 \ 0 \ 2)^t | c = 2) = \left( \frac{1}{3} \right)^0 \cdot \left( \frac{1}{3} \right)^0 \cdot \left( \frac{1}{3} \right)^2 = \frac{1}{9}$$

La muestra  $\mathbf{y}$  se clasifica en la clase 2.

15. (Recuperación Segundo Parcial Junio 2016)

a)

$$p(1) = p(2) = \frac{8}{16} = 0.5$$

$$\hat{\mathbf{p}}_1 = \frac{1}{20} \begin{pmatrix} 1+2+1+1+2+1+1+0 \\ 2+1+0+1+2+0+0+3 \\ 0+0+0+0+0+0+0+0 \\ 1+0+2+1+0+2+3+3 \\ 0+0+0+0+0+0+0+0 \end{pmatrix} = \frac{1}{30} \begin{pmatrix} 9 \\ 9 \\ 0 \\ 12 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.3 \\ 0.3 \\ 0.0 \\ 0.4 \\ 0.0 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \frac{1}{20} \begin{pmatrix} 0+0+0+0+0+0+0+0 \\ 0+0+0+0+0+0+0+0 \\ 1+1+0+1+0+1+1+1 \\ 1+2+1+1+2+1+1+3 \\ 1+3+1+1+1+1+1+3+1 \end{pmatrix} = \frac{1}{30} \begin{pmatrix} 0 \\ 0 \\ 6 \\ 12 \\ 12 \end{pmatrix} = \begin{pmatrix} 0.0 \\ 0.0 \\ 0.2 \\ 0.4 \\ 0.4 \end{pmatrix}$$

b)

$$\hat{\mathbf{p}}_1 = \begin{pmatrix} 0.3 \\ 0.3 \\ 0.0 \\ 0.4 \\ 0.0 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_1 = \frac{1}{2.0} \begin{pmatrix} 0.3+0.2 \\ 0.3+0.2 \\ 0.0+0.2 \\ 0.4+0.2 \\ 0.0+0.2 \end{pmatrix} = \begin{pmatrix} 0.25 \\ 0.25 \\ 0.10 \\ 0.30 \\ 0.10 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 \\ 0.0 \\ 0.2 \\ 0.4 \\ 0.4 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_2 = \frac{1}{2.0} \begin{pmatrix} 0.0+0.2 \\ 0.0+0.2 \\ 0.2+0.2 \\ 0.4+0.2 \\ 0.4+0.2 \end{pmatrix} = \begin{pmatrix} 0.10 \\ 0.10 \\ 0.20 \\ 0.30 \\ 0.30 \end{pmatrix}$$

c)

$$\hat{\mathbf{p}}_1 = \begin{pmatrix} 0.4 \\ 0.3 \\ 0.0 \\ 0.3 \\ 0.0 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_1 = \begin{pmatrix} 0.4 - 0.05 + \frac{1}{5} \cdot 0.15 \\ 0.3 - 0.05 + \frac{1}{5} \cdot 0.15 \\ 0.0 + \frac{1}{5} \cdot 0.15 \\ 0.3 - 0.05 + \frac{1}{5} \cdot 0.15 \\ 0.0 + \frac{1}{5} \cdot 0.15 \end{pmatrix} = \begin{pmatrix} 0.38 \\ 0.28 \\ 0.03 \\ 0.28 \\ 0.03 \end{pmatrix}$$

$$\hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 \\ 0.0 \\ 0.2 \\ 0.4 \\ 0.4 \end{pmatrix} \rightarrow \hat{\mathbf{p}}_2 = \begin{pmatrix} 0.0 + \frac{1}{5} \cdot 0.15 \\ 0.0 + \frac{1}{5} \cdot 0.15 \\ 0.2 - 0.05 + \frac{1}{5} \cdot 0.15 \\ 0.4 - 0.05 + \frac{1}{5} \cdot 0.15 \\ 0.4 - 0.05 + \frac{1}{5} \cdot 0.15 \end{pmatrix} = \begin{pmatrix} 0.03 \\ 0.03 \\ 0.18 \\ 0.38 \\ 0.38 \end{pmatrix}$$

d) En nuestro caso, dado que las priors son idénticas, la regla de clasificación se reduce a:

$$p(\mathbf{y} = (1 \ 1 \ 1 \ 1 \ 1) \mid c = 1) = 0.38 \cdot 0.28 \cdot 0.03 \cdot 0.28 \cdot 0.03 = 2.7 \cdot 10^{-5}$$

$$p(\mathbf{y} = (1 \ 1 \ 1 \ 1 \ 1) \mid c = 2) = 0.03 \cdot 0.03 \cdot 0.18 \cdot 0.38 \cdot 0.38 = 2.3 \cdot 10^{-5}$$

La muestra  $\mathbf{y}$  se clasifica en la clase 1.



16. ■ Caso 1:

$$-g_A(\mathbf{x}) = x_1^2 + x_2^2 - 6x_1 + 9$$

Frontera:  $x_1 = x_2$

$$-g_B(\mathbf{x}) = x_1^2 + x_2^2 - 6x_1 + 9$$

■ Caso 2:

$$-g_A(\mathbf{x}) = 2x_1^2 + x_2^2 - 2x_1x_2 + 6x_1 - 10x_2 + 29$$

Frontera:  $x_1 = 3$

$$-g_B(\mathbf{x}) = 2x_1^2 + x_2^2 - 2x_1x_2 - 10x_2 + 41$$

■ Caso 3:

$$-g_A(\mathbf{x}) = 5x_1^2 + x_2^2 - 4x_1x_2$$

Frontera:  $x_2 = 2x_1 + 2$

$$-g_B(\mathbf{x}) = 5x_1^2 + x_2^2 - 4x_1x_2 + 16x_1 - 8x_2 + 16$$

■ Caso 4:

$$-g_A(\mathbf{x}) = -5\log 2 + 8x_1^2 + 4x_2^2$$

Frontera:  $2x_1^2 + x_2^2 + 4x_2 = \log 2 + 4$

$$-g_B(\mathbf{x}) = -3\log 2 + 8 + 4x_1^2 + 2x_2^2 - 8x_2$$

■ Caso 5:

$$-g_A(\mathbf{x}) = -4\log 2 + 2x_1^2 + 8x_2^2$$

Frontera:  $2x_1^2 - 6x_2^2 - 8x_2 + \log 2 + 8 = 0$

$$-g_B(\mathbf{x}) = -3\log 2 + 8 + 4x_1^2 + 2x_2^2 - 8x_2$$

■ Caso 6:

$$-g_A(\mathbf{x}) = -4\log 2 + 8x_1^2 + 2x_2^2$$

Frontera:  $4x_1^2 + 8x_2 = \log 2 + 8$

$$-g_B(\mathbf{x}) = -3\log 2 + 8 + 4x_1^2 + 2x_2^2 - 8x_2$$

■ Caso 7:

$$-g_A(\mathbf{x}) = -4\log 2 + 4x_1^2 + 4x_2^2$$

Frontera:  $2x_2^2 + 8x_2 = \log 2 + 8$

$$-g_B(\mathbf{x}) = -3\log 2 + 8 + 4x_1^2 + 2x_2^2 - 8x_2$$

17. a)  $P(1) = P(2) = \frac{1}{2}$ ,  $\mu_1 = \begin{pmatrix} 4 \\ 6 \end{pmatrix}$ ,  $\mu_2 = \begin{pmatrix} 8 \\ 3 \end{pmatrix}$ ,  $\Sigma_1 = \Sigma_2 = \begin{pmatrix} 2 & 0 \\ 0 & 6 \end{pmatrix}$

$$g_1(\mathbf{x}) = \frac{1}{2}x_1^2 - \frac{1}{6}x_2^2 - 4x_1 - 2x_2 + 14, g_2(\mathbf{x}) = \frac{1}{2}x_1^2 - \frac{1}{6}x_2^2 - 8x_1 - x_2 + \frac{67}{2}$$

b)  $8x_1 - 2x_2 - 39 = 0$

c) Clases 1 y 2, respectivamente

18. a)  $\mu_A = 1.1$ ,  $\mu_B = 1.28$ ,  $\sigma_A^2 = 0.02$ ,  $\sigma_B^2 = 0.0056$ ,

$$g_A(x) = P(A)(0.02)^{-\frac{1}{2}} \exp(-25(x - 1.1)^2) \quad g_B(x) = P(B)(0.0056)^{-\frac{1}{2}} \exp\left(-\frac{(x - 1.28)^2}{0.0112}\right)$$

b)  $64.286x^2 - 173.57x + 176.536 + \log P(A) + \log P(B) - \frac{1}{2} \log 0.02 - \frac{1}{2} \log 0.0056 = 0$

c) Clase A

19.  $p(\mathbf{x}|A) \approx 0.205$ ,  $p(\mathbf{x}|B) \approx 0.373$ ,  $p(\mathbf{x}|C) \approx 0.086$

20. (Examen Primer Parcial 2013)

Para clase 1:  $p(0.5|1) = \frac{1}{2\sqrt{2\pi}} \cdot e^{-\frac{1}{2}\left(\frac{0.5-0}{2}\right)^2} = \frac{1}{2} \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{1}{32}}$

Para clase 2:  $p(0.5|2) = \frac{1}{1\sqrt{2\pi}} \cdot e^{-\frac{1}{2}\left(\frac{0.5-1}{1}\right)^2} = \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{1}{8}}$

Tomando log en clase 1:  $\log p(0.5|1) = \log \frac{1}{2} + \log \frac{1}{\sqrt{2\pi}} - \frac{1}{32}$

Tomando log en clase 2:  $\log p(0.5|2) = \log \frac{1}{\sqrt{2\pi}} - \frac{1}{8}$

Llamando  $K = \log \frac{1}{\sqrt{2\pi}}$ , tenemos para clase 1:  $\log p(0.5|1) = -\log 2 - \frac{1}{32} + K = -0.69 - 0.03 + K = -0.72 + K$

Y para clase 2:  $\log p(0.5|2) = -\frac{1}{8} + K = -0.13 + K = -0.13 + K$

Por tanto, al tener idénticas probabilidades a priori, se clasifica en clase 2

21. (Examen Recuperación Segundo Parcial 2013)

Usando clasificación por máxima verosimilitud y regla de Bayes, el problema se reduce a calcular

$$c^* = \arg \max_{c \in \{A, B\}} P(c)p(\mathbf{x}|c)$$

Por tanto:

$$p(\mathbf{x}|A) = \frac{1}{|\Sigma_A|^{\frac{1}{2}} 2\pi} \cdot e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_A)^t \Sigma_A^{-1}(\mathbf{x}-\boldsymbol{\mu}_A)} = \frac{1}{2\sqrt{2}\pi} \cdot e^{-\frac{1}{2} \begin{pmatrix} 0 & -2 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & \frac{1}{2} \end{pmatrix} \begin{pmatrix} 0 \\ -2 \end{pmatrix}} = \frac{1}{2\sqrt{2}\pi} \cdot e^{-1}$$

$$p(\mathbf{x}|B) = \frac{1}{|\Sigma_B|^{\frac{1}{2}} 2\pi} \cdot e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu}_B)^t \Sigma_B^{-1}(\mathbf{x}-\boldsymbol{\mu}_B)} = \frac{1}{2\sqrt{3}\pi} \cdot e^{-\frac{1}{2} \begin{pmatrix} 1 & 0 \end{pmatrix} \begin{pmatrix} \frac{1}{3} & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix}} = \frac{1}{2\sqrt{3}\pi} \cdot e^{-\frac{1}{6}}$$

$$P(A|\mathbf{x}) = P(A)p(\mathbf{x}|A) = 0.4 \cdot \frac{1}{2\sqrt{2}\pi} \cdot e^{-1} \approx 0.0166$$

$$P(B|\mathbf{x}) = P(B)p(\mathbf{x}|B) = 0.6 \cdot \frac{1}{2\sqrt{3}\pi} \cdot e^{-\frac{1}{6}} \approx 0.0467$$

Por tanto, se clasifica en la clase **B**.

22. (Examen Segundo Parcial 2014)

a) En general, la función discriminante de un clasificador basado en la regla de Bayes se define como

$$g_c(\mathbf{x}) = p(c) \cdot p(\mathbf{x}|c)$$

o de forma equivalente

$$g_c(\mathbf{x}) = \log p(c) + \log p(\mathbf{x}|c)$$

siendo

$$p(\mathbf{x}|c) \sim \mathcal{N}_2(\boldsymbol{\mu}_c, \Sigma_c) = (2\pi)^{-1} \cdot \det \Sigma_c^{-\frac{1}{2}} \cdot \exp \left( -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_c)^t \Sigma_c^{-1}(\mathbf{x} - \boldsymbol{\mu}_c) \right)$$

aplicamos logaritmo neperiano y operamos para simplificar la expresión resultante eliminando la constante  $(2\pi)^{-1}$

$$g_c(\mathbf{x}) = -\frac{1}{2}\mathbf{x}^t \Sigma_c^{-1} \mathbf{x} + \boldsymbol{\mu}_c^t \Sigma_c^{-1} \mathbf{x} + \left( \log p(c) - \frac{1}{2} \log \det \Sigma_c - \frac{1}{2} \boldsymbol{\mu}_c^t \Sigma_c^{-1} \boldsymbol{\mu}_c \right)$$

Las funciones discriminantes de las clases serían:

$$\begin{aligned} g_A(\mathbf{x}) &= -\frac{1}{2} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}^t \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}^{-1} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \end{pmatrix}^t \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}^{-1} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \\ &+ \left( \log \frac{1}{2} - \frac{1}{2} \log \det \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} - \frac{1}{2} \begin{pmatrix} 0 \\ 0 \end{pmatrix}^t \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}^{-1} \begin{pmatrix} 0 \\ 0 \end{pmatrix} \right) \\ &= -\frac{1}{4}x_1^2 - \frac{1}{4}x_2^2 + \log \frac{1}{2} - \frac{1}{2} \log 4 \end{aligned}$$

(1)

$$\begin{aligned} g_B(\mathbf{x}) &= -\frac{1}{2} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}^t \begin{pmatrix} 1 & -1 \\ -1 & 2 \end{pmatrix}^{-1} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \begin{pmatrix} 2 \\ 2 \end{pmatrix}^t \begin{pmatrix} 1 & -1 \\ -1 & 2 \end{pmatrix}^{-1} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \\ &+ \left( \log \frac{1}{4} - \frac{1}{2} \log \det \begin{pmatrix} 1 & -1 \\ -1 & 2 \end{pmatrix} - \frac{1}{2} \begin{pmatrix} 2 \\ 2 \end{pmatrix}^t \begin{pmatrix} 1 & -1 \\ -1 & 2 \end{pmatrix}^{-1} \begin{pmatrix} 2 \\ 2 \end{pmatrix} \right) \\ &= -x_1^2 - x_1x_2 - \frac{1}{2}x_2^2 + 6x_1 + 4x_2 + \log \frac{1}{4} - 10 \end{aligned}$$

(2)

$$\begin{aligned}
g_C(\mathbf{x}) &= -\frac{1}{2} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}^t \begin{pmatrix} 1 & -1 \\ -1 & 2 \end{pmatrix}^{-1} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \begin{pmatrix} -2 \\ -2 \end{pmatrix}^t \begin{pmatrix} 1 & -1 \\ -1 & 2 \end{pmatrix}^{-1} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \\
&+ \left( \log \frac{1}{4} - \frac{1}{2} \log \det \begin{pmatrix} 1 & -1 \\ -1 & 2 \end{pmatrix} - \frac{1}{2} \begin{pmatrix} -2 \\ -2 \end{pmatrix}^t \begin{pmatrix} 1 & -1 \\ -1 & 2 \end{pmatrix}^{-1} \begin{pmatrix} -2 \\ -2 \end{pmatrix} \right) \\
&= -x_1^2 - x_1x_2 - \frac{1}{2}x_2^2 - 6x_1 - 4x_2 + \log \frac{1}{4} - 10
\end{aligned}$$

b) La frontera de decisión entre las clases  $A$  y  $B$  se obtiene igualando sus respectivas funciones discriminantes

$$g_A(\mathbf{x}) = g_B(\mathbf{x})$$

Por tanto,

$$-\frac{1}{4}x_1^2 - \frac{1}{4}x_2^2 + \log \frac{1}{2} - \frac{1}{2} \log 4 = -x_1^2 - x_1x_2 - \frac{1}{2}x_2^2 + 6x_1 + 4x_2 + \log \frac{1}{4} - 10$$

que resulta en una curva cuadrática

$$\frac{3}{4}x_1^2 + x_1x_2 + \frac{1}{4}x_2^2 - 6x_1 - 4x_2 + 10 = 0$$

c) Al igual que en el apartado b) igualamos las funciones discriminantes, pero en este caso las de las clase  $B$  y  $C$

$$-x_1^2 - x_1x_2 - \frac{1}{2}x_2^2 + 6x_1 + 4x_2 + \log \frac{1}{4} - 10 = -x_1^2 - x_1x_2 - \frac{1}{2}x_2^2 - 6x_1 - 4x_2 + \log \frac{1}{4} - 10$$

que como esperábamos definen una frontera de decisión lineal

$$3x_1 + 2x_2 = 0 \rightarrow x_2 = -\frac{3}{2}x_1$$

dado que la matriz de covarianza es común a ambas clases.

d) Aplicamos la regla de clasificación a la muestra  $\mathbf{y}$

$$\hat{c}(\mathbf{y}) = \arg \max_c g_c(\mathbf{y})$$

Esto es

$$g_A(\mathbf{y}) = -\frac{1}{4}1^2 - \frac{1}{4}1^2 + \log \frac{1}{2} - \frac{1}{2} \log 4 = -1.89$$

$$g_B(\mathbf{y}) = -1^2 - 1 - \frac{1}{2}1^2 + 6 + 4 + \log \frac{1}{4} - 10 = -3.89$$

$$g_C(\mathbf{y}) = -1^2 - 1 - \frac{1}{2}1^2 - 6 - 4 + \log \frac{1}{4} - 10 = -23.89$$

Por tanto,  $\hat{c}(\mathbf{y}) = A$ .

## 23. (Examen Segundo Parcial 2016)

a) En general, la función discriminante de un clasificador basado en la regla de Bayes se define como

$$g_c(\mathbf{x}) = p(c) \cdot p(\mathbf{x}|c)$$

o de forma equivalente

$$g_c(\mathbf{x}) = \log p(c) + \log p(\mathbf{x}|c)$$

siendo

$$p(\mathbf{x} | c) \sim \mathcal{N}_2(\boldsymbol{\mu}_c, \Sigma_c) = (2\pi)^{-1} \cdot \det \Sigma_c^{-\frac{1}{2}} \cdot \exp \left( -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_c)^t \Sigma_c^{-1} (\mathbf{x} - \boldsymbol{\mu}_c) \right)$$

aplicamos logaritmo neperiano y operamos para simplificar la expresión resultante eliminando la constante  $(2\pi)^{-1}$

$$g_c(\mathbf{x}) = -\frac{1}{2}\mathbf{x}^t \Sigma_c^{-1} \mathbf{x} + \boldsymbol{\mu}_c^t \Sigma_c^{-1} \mathbf{x} + \left( \log p(c) - \frac{1}{2} \log \det \Sigma_c - \frac{1}{2} \boldsymbol{\mu}_c^t \Sigma_c^{-1} \boldsymbol{\mu}_c \right)$$

Las funciones discriminantes de las clases serían:

$$\begin{aligned}
 g_A(\mathbf{x}) &= -\frac{1}{2} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}^t \begin{pmatrix} 1/2 & 0 \\ 0 & 2 \end{pmatrix}^{-1} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \begin{pmatrix} 0 \\ 0 \end{pmatrix}^t \begin{pmatrix} 1/2 & 0 \\ 0 & 2 \end{pmatrix}^{-1} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \\
 &+ \left( \log \frac{1}{2} - \frac{1}{2} \log \det \begin{pmatrix} 1/2 & 0 \\ 0 & 2 \end{pmatrix} - \frac{1}{2} \begin{pmatrix} 0 \\ 0 \end{pmatrix}^t \begin{pmatrix} 1/2 & 0 \\ 0 & 2 \end{pmatrix}^{-1} \begin{pmatrix} 0 \\ 0 \end{pmatrix} \right) \\
 &= -x_1^2 - \frac{1}{4}x_2^2 - \log 2
 \end{aligned}$$

$$\begin{aligned}
 g_B(\mathbf{x}) &= -\frac{1}{2} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}^t \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}^{-1} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \begin{pmatrix} 0 \\ 1 \end{pmatrix}^t \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}^{-1} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \\
 &+ \left( \log \frac{1}{2} - \frac{1}{2} \log \det \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} - \frac{1}{2} \begin{pmatrix} 0 \\ 1 \end{pmatrix}^t \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}^{-1} \begin{pmatrix} 0 \\ 1 \end{pmatrix} \right) \\
 &= -\frac{1}{2}x_1^2 - \frac{1}{4}x_2^2 + \frac{1}{2}x_2 - \log 2 - \frac{1}{2} \log 2 - \frac{1}{4}
 \end{aligned}$$

b) La frontera de decisión entre las clases  $A$  y  $B$  se obtiene igualando sus respectivas funciones discriminantes

$$g_A(\mathbf{x}) = g_B(\mathbf{x})$$


Por tanto,

$$-x_1^2 - \frac{1}{4}x_2^2 - \log 2 = -\frac{1}{2}x_1^2 - \frac{1}{4}x_2^2 + \frac{1}{2}x_2 - \log 2 - \frac{1}{2} \log 2 - \frac{1}{4}$$

que resulta en una parábola vertical

$$x_2 = -x_1^2 + \log 2 + \frac{1}{2} \approx -x_1^2 + 1.2$$

c)



d) El suavizado por *flat smoothing* de una matriz de covarianza  $\hat{\Sigma}_c$  se calcula como una combinación lineal de dicha matriz y la matriz de identidad  $I$ , de forma que la matriz de covarianzas resultante es:

$$\tilde{\Sigma}_c = \alpha \hat{\Sigma}_c + (1 - \alpha) I \quad \forall c$$

En nuestro caso

$$\begin{aligned}
 \tilde{\Sigma}_A &= \alpha \begin{pmatrix} \frac{1}{2} & 0 \\ 0 & 2 \end{pmatrix} + (1 - \alpha) \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} \frac{\alpha}{2} + 1 & 0 \\ 0 & \alpha + 1 \end{pmatrix} \\
 \tilde{\Sigma}_B &= \alpha \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix} + (1 - \alpha) \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & \alpha + 1 \end{pmatrix}
 \end{aligned}$$

Por otra parte, sabemos que un clasificador Gaussiano es lineal si la matriz de covarianzas es la misma para todas las clases. Si igualamos  $\tilde{\Sigma}_A$  y  $\tilde{\Sigma}_B$  para los elementos no nulos, tenemos

$$\begin{aligned}\frac{\alpha}{2} + 1 &= 1 \\ \alpha + 1 &= \alpha + 1\end{aligned}$$

Si resolvemos este sistema de ecuaciones, vemos que la solución es  $\alpha = 0$ , es decir, obviamente si  $\tilde{\Sigma}_A = \tilde{\Sigma}_B = I$ .

24. (Examen Recuperación Segundo Parcial 2017)

a) En el caso de matrices de covarianza común, la función discriminante se define como:

$$g_c(\mathbf{x}) = \mathbf{w}_c^t \mathbf{x} + b_c$$

donde

$$\mathbf{w}_c = \Sigma^{-1} \boldsymbol{\mu}_c \quad b_c = \log P(c) - \frac{1}{2} \boldsymbol{\mu}_c^t \Sigma^{-1} \boldsymbol{\mu}_c$$

Las funciones discriminantes de las clases serían:

$$g_A(\mathbf{x}) = \mathbf{w}_A^t \mathbf{x} + b_A$$

$$\mathbf{w}_A = \Sigma^{-1} \boldsymbol{\mu}_A = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 0 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$b_A = \log P(A) - \frac{1}{2} \boldsymbol{\mu}_A^t \Sigma^{-1} \boldsymbol{\mu}_A = \log \frac{1}{4} - \frac{1}{2} \begin{pmatrix} 0 \\ 0 \end{pmatrix}^t \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 0 \\ 0 \end{pmatrix} = -\log 4$$

$$g_A(\mathbf{x}) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}^t \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} - \log 4 = -\log 4$$

$$g_B(\mathbf{x}) = \mathbf{w}_B^t \mathbf{x} + b_B$$

$$\mathbf{w}_B = \Sigma^{-1} \boldsymbol{\mu}_B = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$b_B = \log P(B) - \frac{1}{2} \boldsymbol{\mu}_B^t \Sigma^{-1} \boldsymbol{\mu}_B = \log \frac{3}{4} - \frac{1}{2} \begin{pmatrix} 1 \\ 1 \end{pmatrix}^t \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}^{-1} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \log \frac{3}{4} - 1$$

$$g_B(\mathbf{x}) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}^t \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \log \frac{3}{4} - 1 = x_1 + x_2 + \log 3 - \log 4 - 1$$

b) La frontera de decisión entre las clases  $A$  y  $B$  se obtiene igualando sus respectivas funciones discriminantes

$$g_A(\mathbf{x}) = g_B(\mathbf{x})$$

Por tanto,

$$-\log 4 = x_1 + x_2 + \log 3 - \log 4 - 1$$

$$0 = x_1 + x_2 + \log 3 - 1$$

$$x_2 = -x_1 - \log 3 + 1 = -x_1 - 0.1$$

que es una frontera lineal.

c)

